

# **Rapport de TP**

Pipeline OLTP → ETL Pentaho PDI → Data Warehouse →  
Reporting Power BI

Fait par :**Khadija Nachid Idrissi**

:**Rajae Fdili**

:**Aya Hamim**

**Année Universitaire : 2024–2025**

# Table des matières

0.1	Introduction . . . . .	4
0.1.1	OLTP vs OLAP . . . . .	4
0.1.2	Rôle de Pentaho Data Integration (ETL) . . . . .	4
0.1.3	Rôle du Data Warehouse . . . . .	4
0.1.4	Rôle de Power BI . . . . .	5
0.2	Modèle OLTP . . . . .	6
0.2.1	Contexte . . . . .	6
0.2.2	Structure de la base OLTP . . . . .	6
0.2.3	Script SQL de création de la base . . . . .	6
0.3	Vérification de la structure de la base OLTP . . . . .	7
0.3.1	Affichage des tables . . . . .	7
0.3.2	Description des tables . . . . .	7
0.3.3	Vérification de la génération des fichiers CSV . . . . .	9
0.3.4	Vérification de la génération des fichiers CSV . . . . .	9
0.4	Importation des CSV dans MySQL . . . . .	11
0.4.1	Étapes d'importation . . . . .	11
0.4.2	Vérification de l'importation . . . . .	11
0.5	Création du Data Warehouse . . . . .	12
0.5.1	Tables créées . . . . .	12
0.5.2	Vérification de la création des tables . . . . .	12
0.5.3	Remarques . . . . .	14
0.6	Pentaho PDI – Configuration et Transformations . . . . .	14
0.6.1	Configuration de Pentaho PDI . . . . .	14
0.6.2	Vérification des connexions . . . . .	14
0.7	Transformation 1 : Chargement de la dimension DimClient . . . . .	15
0.7.1	Création de la transformation . . . . .	15
0.7.2	Extraction et chargement . . . . .	15
0.7.3	Résultat obtenu . . . . .	16
0.8	Transformation 2 : Chargement de la dimension DimProduit . . . . .	16

0.8.1	Création de la transformation . . . . .	17
0.8.2	Extraction et renommage des colonnes . . . . .	17
0.8.3	Chargement dans la dimension . . . . .	17
0.8.4	Résultat obtenu . . . . .	17
0.9	Transformation 3 : Génération de la dimension DimDate . . . . .	18
0.9.1	Création de la transformation . . . . .	18
0.9.2	Génération des dates et calcul des composantes . . . . .	19
0.9.3	Chargement dans la dimension . . . . .	19
0.9.4	Résultat obtenu . . . . .	19
0.10	Transformation 4 : Chargement de la table de faits FactVentes . . . . .	20
0.10.1	Création de la transformation . . . . .	20
0.10.2	Extraction des données OLTP . . . . .	20
0.10.3	Lookup des dimensions . . . . .	20
0.10.4	Calcul du montant total . . . . .	21
0.10.5	Sélection des champs finaux et chargement . . . . .	21
0.10.6	Résultat obtenu . . . . .	21
0.11	Création du Job d'Orchestration Pentaho . . . . .	22
0.11.1	Structure du Job . . . . .	22
0.11.2	Étapes de création . . . . .	23
0.11.3	Capture d'écran du Job . . . . .	23
0.12	Requêtes OLAP sur le Data Warehouse . . . . .	23
0.12.1	Requête 1 : Chiffre d'affaires par ville . . . . .	23
0.12.2	Requête 2 : Chiffre d'affaires par catégorie de produit . . . . .	24
0.12.3	Requête 3 : Évolution mensuelle des ventes . . . . .	24
0.12.4	Requête 4 : Top 10 des produits les plus vendus . . . . .	25
0.12.5	Requête 5 : Analyse croisée trimestre-catégorie . . . . .	25
0.12.6	Avantages du schéma en étoile . . . . .	26
0.13	Power BI - Reporting et Visualisation . . . . .	26
0.13.1	Prérequis . . . . .	26
0.13.2	Étape 1 : Se connecter à MySQL depuis Power BI . . . . .	26
0.13.3	Étape 2 : Importer les tables du Data Warehouse . . . . .	28
0.13.4	Étape 3 : Vérifier et configurer le modèle de données . . . . .	28
0.14	Étape 4 : Créer les visualisations . . . . .	29
0.14.1	Visuel 1 : Chiffre d'affaires par ville (Graphique à barres) . . . . .	29
0.14.2	Visuel 2 : Chiffre d'affaires par catégorie (Graphique en secteurs) . . . . .	30
0.14.3	Visuel 3 : Évolution des ventes mensuelles (Graphique en courbes) . . . . .	31
0.14.4	Visuel 4 : Top 10 des produits (Graphique à barres horizontales) . . . . .	31

0.15 Étape 5 : Ajouter des segments (Slicers) pour l'interactivité . . . . .	32
0.15.1 5.1 - Ajouter un segment Année . . . . .	32
0.15.2 5.2 - Ajouter un segment Catégorie . . . . .	33
0.15.3 5.3 - Tester l'interactivité . . . . .	34
0.16 Étape 6 : Créer des mesures DAX (optionnel mais recommandé) . . . . .	34
0.16.1 6.1 - Mesure “CA Total” . . . . .	34
0.16.2 6.2 - Mesure “Nombre de ventes” . . . . .	35
0.16.3 6.3 - Mesure “Panier Moyen” . . . . .	35
0.16.4 6.4 - Mesure “Clients Uniques” . . . . .	36
0.16.5 6.5 - Utiliser les mesures . . . . .	36
0.17 Étape 9 : Créer une page de détails (Drill-through) . . . . .	37
0.17.1 9.1 - Créeer une nouvelle page . . . . .	37
0.17.2 9.3 - Ajouter des visuels détaillés . . . . .	38
0.17.3 9.4 - Tester le drill-through . . . . .	39

## 0.1 Introduction

Ce rapport présente la construction complète d'un pipeline décisionnel allant d'une base de données opérationnelle (OLTP) à la création d'un Data Warehouse alimenté par un processus ETL réalisé dans Pentaho PDI, puis analysé dans Power BI.

L'objectif de ce TP est de mettre en place une architecture permettant à l'entreprise fictive **TechStore** de transformer ses données brutes en informations utiles pour la prise de décision.

### 0.1.1 OLTP vs OLAP

**OLTP (Online Transaction Processing).** Les systèmes OLTP gèrent les opérations quotidiennes :

- gestion des clients,
- enregistrement des commandes,
- mise à jour des produits.

Ils sont fortement normalisés pour éviter la redondance et garantir l'intégrité.

**OLAP (Online Analytical Processing).** Les systèmes OLAP sont utilisés pour l'analyse :

- tendances de ventes,
- performance des produits,
- comportement client.

Ils s'appuient sur un **Data Warehouse**, structuré en schémas en étoile.

### 0.1.2 Rôle de Pentaho Data Integration (ETL)

Pentaho PDI permet :

- l'extraction des données OLTP,
- le nettoyage, la transformation, l'harmonisation,
- le chargement vers le Data Warehouse.

### 0.1.3 Rôle du Data Warehouse

Le Data Warehouse regroupe des données :

- intégrées,
- nettoyées,
- historisées,
- optimisées pour l'analyse.

Il constitue la base des rapports Power BI.

#### 0.1.4 Rôle de Power BI

Power BI permet :

- la connexion au DWH,
- la création de tableaux de bord,
- une visualisation dynamique des indicateurs.

## 0.2 Modèle OLTP

### 0.2.1 Contexte

TechStore est une entreprise spécialisée dans la vente de matériel électronique. La base OLTP constitue la source initiale des données, représentant les transactions quotidiennes : clients, produits, commandes et lignes de commande.

### 0.2.2 Structure de la base OLTP

La base de données `ventes_oltp` contient quatre tables principales :

- `clients`,
- `produits`,
- `commandes`,
- `lignes_commandes`.

Ces tables sont reliées par des clés étrangères pour former un modèle relationnel normalisé.

### 0.2.3 Script SQL de création de la base

## 0.3 Vérification de la structure de la base OLTP

Après la création des tables, il est essentiel de vérifier leur existence ainsi que leur structure.

### 0.3.1 Affichage des tables

Commande exécutée :

```
SHOW TABLES;
```

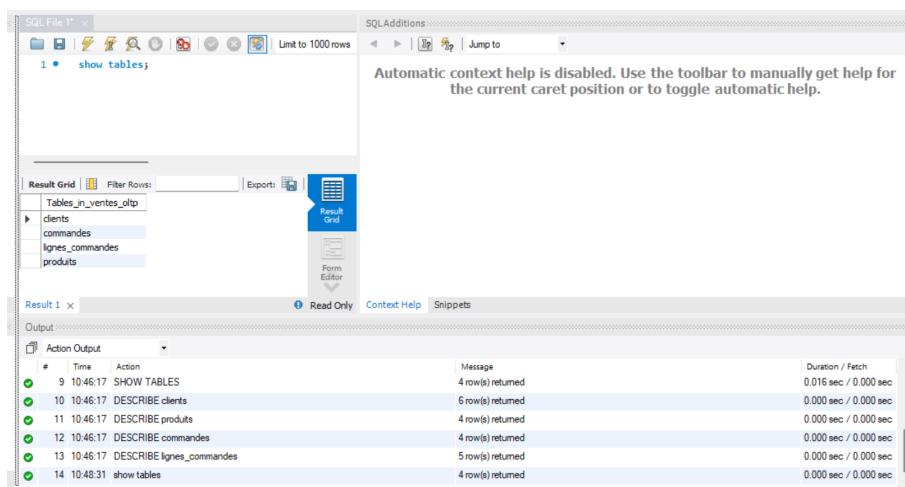


FIGURE 1 – Résultat de la commande SHOW TABLES

### 0.3.2 Description des tables

Table : clients

```
DESCRIBE clients;
```

The screenshot shows the MySQL Workbench interface with the following details:

- SQL Editor:** Contains the command `DESCRIBE clients;`
- Result Grid:** Displays the structure of the 'clients' table with the following columns:
 

Field	Type	Null	Key	Default	Extra
id_client	int	NO	PRI	NULL	auto
nom	varchar(100)	NO		NULL	
prenom	varchar(100)	NO		NULL	
email	varchar(150)	NO	UNI	NULL	
ville	varchar(100)	NO	MUL	NULL	
date_inscription	date	NO	MUL	NULL	
- Action Output:** Shows the history of database actions with their time, action, message, and duration/fetch time.

FIGURE 2 – Structure de la table clients

### Table : produits

`DESCRIBE produits;`

The screenshot shows the MySQL Workbench interface with the following details:

- SQL Editor:** Contains the commands `DESCRIBE clients;` and `describe produits ;`
- Result Grid:** Displays the structure of the 'produits' table with the following columns:
 

Field	Type	Null	Key	Default	Extra
id_produit	int	NO	PRI	NULL	auto
nom_produit	varchar(200)	NO		NULL	
categorie	varchar(100)	NO	MUL	NULL	
prix_unitaire	decimal(10,2)	NO		NULL	
- Action Output:** Shows the history of database actions with their time, action, message, and duration/fetch time.

FIGURE 3 – Structure de la table produits

### Table : commandes

`DESCRIBE commandes;`

```

SQL File 1* x
1
2 • DESCRIBE clients;
3 • describe produits ;
4 • describe commandes ;
5

Result Grid | Filter Rows: Export: Result Grid
Field Type Null Key Default
id_commande int NO PRI NULL auto
id_client int NO MUL NULL
date_commande date NO MUL NULL
montant_total decimal(10,2) NO NULL

Result 6 Result 7 Result 8 x Read Only Context Help Snippets
Output:
Action Output
# Time Action Message Duration / Fetch
16 10:53:44 DESCRIBE clients 6 row(s) returned 0.015 sec / 0.000 sec
17 10:57:23 DESCRIBE clients 6 row(s) returned 0.016 sec / 0.000 sec
18 10:57:23 describe produits 4 row(s) returned 0.000 sec / 0.000 sec
19 10:58:18 DESCRIBE clients 6 row(s) returned 0.000 sec / 0.000 sec
20 10:58:18 describe produits 4 row(s) returned 0.000 sec / 0.000 sec
21 10:58:18 describe commandes 4 row(s) returned 0.000 sec / 0.000 sec

```

FIGURE 4 – Structure de la table commandes

#### Table : lignes\_commandes

DESCRIBE lignes\_commandes;

```

SQL File 1* x
1
2 • DESCRIBE clients;
3 • describe produits ;
4 • describe commandes ;
5 • describe lignes_commandes ;
6 • show tables ;

Result Grid | Filter Rows: Export: Result Grid
Field Type Null Key Default
id_ligne int NO PRI NULL auto
id_commande int NO MUL NULL
id_produit int NO MUL NULL
quantite int NO MUL NULL
prix_unitaire decimal(10,2) NO NULL

Result 16 x Read Only Context Help Snippets
Output:
Action Output
# Time Action Message Duration / Fetch
28 11:00:07 DESCRIBE clients 6 row(s) returned 0.000 sec / 0.000 sec
29 11:00:07 describe produits 4 row(s) returned 0.000 sec / 0.000 sec
30 11:00:07 describe commandes 4 row(s) returned 0.016 sec / 0.000 sec
31 11:00:07 describe ligne_commandes Error Code: 1146. Table 'ventes_otp.ligne_commandes' doesn't exist 0.000 sec
32 11:00:15 show tables 4 row(s) returned 0.000 sec / 0.000 sec
33 11:00:22 describe lignes_commandes 5 row(s) returned 0.000 sec / 0.000 sec

```

FIGURE 5 – Structure de la table lignes\_commandes

### 0.3.3 Vérification de la génération des fichiers CSV

Après l'exécution du script, quatre fichiers CSV doivent être présents : `clients.csv`, `produits.csv`, `commandes.csv`, `lignes_commandes.csv`.

### 0.3.4 Vérification de la génération des fichiers CSV

Après l'exécution du script, quatre fichiers CSV doivent être présents : `clients.csv`, `produits.csv`, `commandes.csv`, `lignes_commandes.csv`.

## Vérification dans Colab / terminal

Pour vérifier que les fichiers ont bien été créés, on peut exécuter la commande suivante dans Colab ou dans un terminal :

```
!ls
```

ou simplement vérifier dans l'explorateur de fichiers de Colab.



```
Génération des données en cours...
...
Génération de 10 000 clients...
Fichier clients.csv créé : 10000 lignes
Génération de 500 produits...
Fichier produits.csv créé : 500 lignes
Génération de 20 000 commandes...
Génération de 100 000 lignes de commandes...
Fichier lignes_commandes.csv créé : 100000 lignes
Fichier commandes.csv créé : 20000 lignes

Génération terminée avec succès !
Fichiers créés : clients.csv, produits.csv, commandes.csv, lignes_commandes.csv
```

Commencez à coder ou à générer avec l'IA.

FIGURE 6 – Fichiers générés dans Colab après l'exécution du script

## Aperçu des données générées

Une fois les fichiers créés, on peut visualiser les premières lignes pour vérifier la cohérence des données. Voici quelques exemples :

...	id_client	nom	prenom	email	ville	date_inscription
0	1	Riou	Frédéric	<a href="mailto:client1@voila.fr">client1@voila.fr</a>	Rennes	2025-02-10
1	2	Moulin	Maurice	<a href="mailto:client2@laposte.net">client2@laposte.net</a>	Lyon	2025-02-05
2	3	Labbé	Nicole	<a href="mailto:client3@hotmail.fr">client3@hotmail.fr</a>	Paris	2024-08-29
3	4	David	Antoine	<a href="mailto:client4@hotmail.fr">client4@hotmail.fr</a>	Reims	2023-07-18
4	5	Bodin	Josette	<a href="mailto:client5@voila.fr">client5@voila.fr</a>	Nice	2024-07-28

FIGURE 7 – Aperçu des 5 premières lignes de clients.csv

	id_produit	nom_produit	categorie	prix_unitaire
0	1	MacBook Pro Ultra	Ordinateurs	100.63
1	2	MacBook Pro Standard	Ordinateurs	778.44
2	3	MacBook Pro Ultra	Ordinateurs	349.86
3	4	MacBook Pro Standard	Ordinateurs	1669.86
4	5	Lenovo ThinkPad Standard	Ordinateurs	1275.30

FIGURE 8 – Aperçu des 5 premières lignes de produits.csv

...	id_commande	id_client	date_commande	montant_total
0	1	69	2023-01-24	13063.92
1	2	8204	2022-01-27	24348.16
2	3	8052	2024-02-06	8588.92
3	4	6813	2024-04-08	8465.77
4	5	6114	2024-03-19	14608.40

FIGURE 9 – Aperçu des 5 premières lignes de commandes.csv

#	♦	Afficher les 5 premières lignes (aperçu)			
		print(df.head())			
...	id_ligne	id_commande	id_produit	quantite	prix_unitaire
0	1	4378	418	2	286.40
1	2	7088	81	5	1609.52
2	3	13473	348	1	625.34
3	4	8834	2	2	778.44
4	5	9423	477	3	1235.72

FIGURE 10 – Aperçu des 5 premières lignes de lignes\_commandes.csv

## Remarques importantes

- Les identifiants des clients et des produits (`id_client`, `id_produit`) réfèrent correctement les tables correspondantes.
- Les dates des commandes sont réparties sur une période de 3 ans (2022-2024).
- Le `montant_total` des commandes correspond à la somme des lignes de commandes.
- Les fichiers CSV sont prêts à être utilisés pour l'ETL avec Pentaho.

## 0.4 Importation des CSV dans MySQL

Les fichiers CSV générés (`clients.csv`, `produits.csv`, `commandes.csv`, `lignes_commandes.csv`) doivent maintenant être importés dans la base `ventes.oltp`.

### 0.4.1 Étapes d'importation

### 0.4.2 Vérification de l'importation

Après l'importation, il est recommandé de vérifier que les fichiers ont bien été chargés et que le nombre de lignes correspond aux données générées.

	table_name	nb_lignes
▶	clients	10000
	produits	500
	commandes	20000
	lignes_commandes	100000

Result 1 × clients 2    produits 3    commandes 4    lignes\_commandes 5    Read Only

FIGURE 11 – Vérification de l'importation dans MySQL Workbench

## 0.5 Crédation du Data Warehouse

Nous avons maintenant créé la base de données `ventes_dwh` avec un schéma en étoile. Cette étape prépare les tables qui seront ensuite alimentées via Pentaho.

### 0.5.1 Tables créées

La base `ventes_dwh` contient les quatre tables suivantes :

- **DimClient** : dimension clients avec clé surrogate et clé source
- **DimProduit** : dimension produits avec clé surrogate et clé source
- **DimDate** : dimension date permettant l'analyse temporelle
- **FactVentes** : table de faits contenant les métriques de ventes

### 0.5.2 Vérification de la création des tables

Après l'exécution du script SQL, nous avons vérifié que les tables existaient et leur structure correspondait aux attentes.

#### Affichage des tables

Tables_in_ventes_dwh
dimclient
dimdate
dimproduit
factventes

Result 6 ×    Read Only

FIGURE 12 – Résultat de la commande `SHOW TABLES` dans `ventes_dwh`

## Description des tables

The screenshot shows the MySQL Workbench interface with the 'Result Grid' tab selected. A table named 'DimClient' is displayed with the following structure:

	Field	Type	Null	Key	Default	Extra
▶	id_client_dim	int	NO	PRI	NULL	auto_increment
	id_client_source	int	NO	UNI	NULL	
	nom_complet	varchar(200)	NO	UNI	NULL	
	email	varchar(150)	NO		NULL	
	ville	varchar(100)	NO	MUL	NULL	

FIGURE 13 – Structure de la table DimClient

## Table DimClient

The screenshot shows the MySQL Workbench interface with the 'Result Grid' tab selected. A table named 'DimProduit' is displayed with the following structure:

	Field	Type	Null	Key	Default	Extra
▶	id_produit_dim	int	NO	PRI	NULL	auto_increment
	id_produit_source	int	NO	UNI	NULL	
	nom_produit	varchar(200)	NO		NULL	
	categorie	varchar(100)	NO	MUL	NULL	

FIGURE 14 – Structure de la table DimProduit

## Table DimProduit

The screenshot shows the MySQL Workbench interface with the 'Result Grid' tab selected. A table named 'DimDate' is displayed with the following structure:

	Field	Type	Null	Key	Default	Extra
▶	id_date_dim	int	NO	PRI	NULL	
	date_complete	date	NO	UNI	NULL	
	annee	int	NO	MUL	NULL	
	trimestre	int	NO	MUL	NULL	
	mois	int	NO	MUL	NULL	
	nom_mois	varchar(20)	NO		NULL	

FIGURE 15 – Structure de la table DimDate

## Table DimDate

Field	Type	Null	Key	Default	Extra
id_vente	int	NO	PRI	NULL	auto_increment
id_client_dim	int	NO	MUL	NULL	
id_produit_dim	int	NO	MUL	NULL	
id_date_dim	int	NO	MUL	NULL	
quantite	int	NO		NULL	
prix_unitaire	decimal(10,2)	NO		NULL	

FIGURE 16 – Structure de la table FactVentes

## Table FactVentes

### 0.5.3 Remarques

- Toutes les tables sont vides mais prêtes à recevoir les données transformées depuis l’OLTP via Pentaho PDI.
- Les clés surrogates permettent de gérer l’historique et les relations avec les faits.
- Les indices sont créés pour optimiser les requêtes analytiques dans le Data Warehouse.

## 0.6 Pentaho PDI – Configuration et Transformations

Cette partie présente la configuration initiale de Pentaho Data Integration (PDI) et la mise en place des connexions nécessaires entre la base OLTP et le Data Warehouse.

### 0.6.1 Configuration de Pentaho PDI

Avant de commencer les transformations, nous devons configurer les connexions aux deux bases MySQL. Après avoir installé Pentaho Data Integration, nous lançons l’outil **Spoon**.

### 0.6.2 Vérification des connexions

Après validation, les deux connexions apparaissent dans la liste *Database connections*. La figure suivante illustre l’écran de configuration dans PDI.

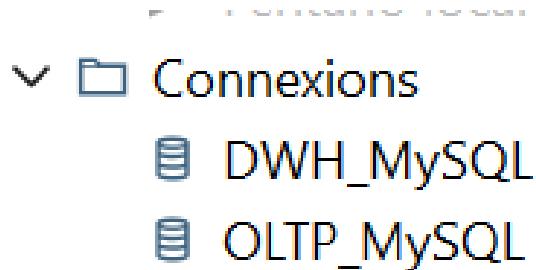


FIGURE 17 – Vérification des connexions OLTP et DWH dans Pentaho PDI

## 0.7 Transformation 1 : Chargement de la dimension DimClient

Cette première transformation a pour objectif d'extraire les données clients depuis la base OLTP, de renommer certains champs, puis de charger le résultat dans la table DimClient du Data Warehouse.

### 0.7.1 Création de la transformation

Une nouvelle transformation `dim_client.ktr` a été créée dans Pentaho PDI. La figure ci-dessous illustre l'architecture générale composée de trois étapes principales :

- **Table Input** : extraction des clients depuis la base OLTP.
- **Select Values** : renommage et sélection des colonnes nécessaires.
- **Table Output** : chargement des données dans la table `DimClient` du DWH.

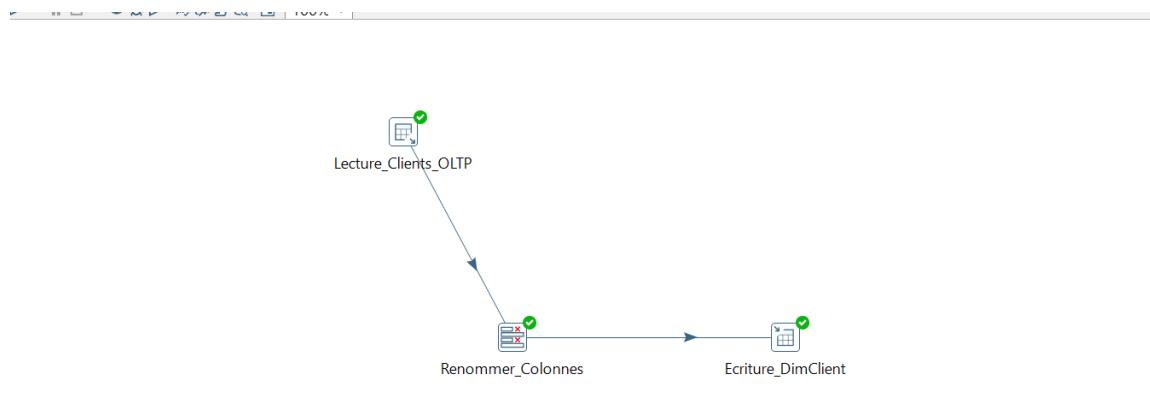


FIGURE 18 – Architecture de la transformation DimClient dans Pentaho PDI

### 0.7.2 Extraction et chargement

L'étape **Table Input** utilise la connexion `OLTP_MySQL` avec la requête SQL :

`[language=SQL] SELECT idclient, CONCAT(prenom, ' ', nom) AS nom_complet, email, ville FROM ...`

Les colonnes sont ensuite renommées via **Select Values**, puis les données sont insérées dans la table DimClient à l'aide de l'étape **Table Output**, reliée au schéma DWH\_MySQL.

### 0.7.3 Résultat obtenu

Après exécution de la transformation, 10 000 lignes sont chargées dans la dimension. La figure suivante montre la vérification dans MySQL Workbench :

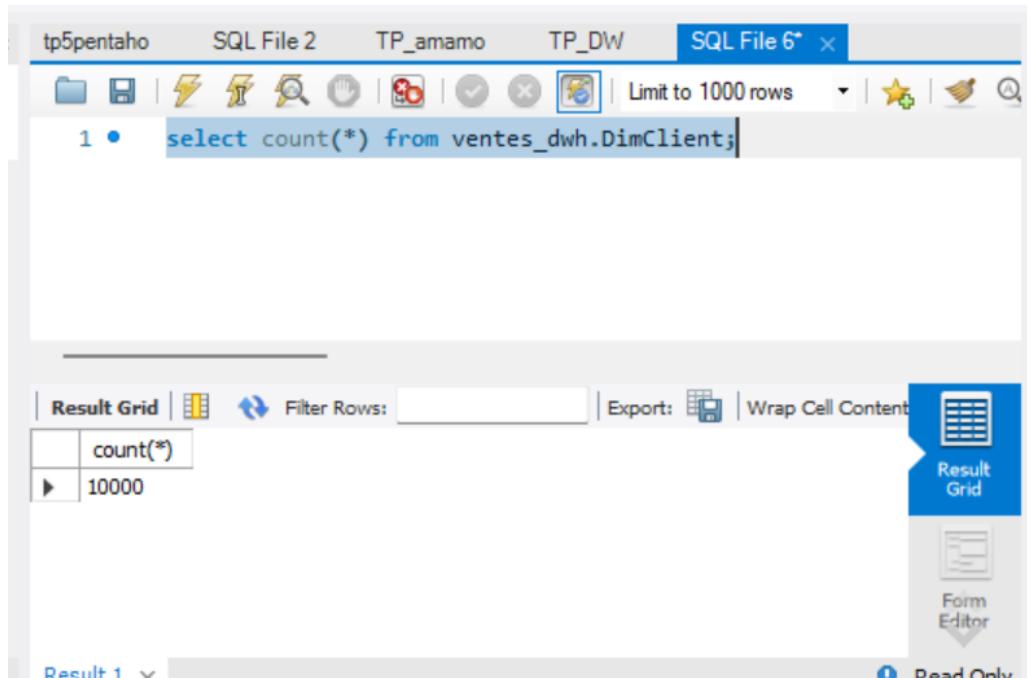


FIGURE 19 – Vérification du chargement de DimClient dans MySQL Workbench

La commande utilisée pour vérifier est :

```
[language=SQL] SELECT COUNT(*) FROM ventes_dwh.DimClient;
```

Le résultat obtenu est bien de **10 000 lignes**, ce qui confirme le bon fonctionnement de la transformation.

## 0.8 Transformation 2 : Chargement de la dimension DimProduit

Cette transformation a pour objectif d'extraire les données produits depuis la base OLTP, de renommer certains champs, puis de charger le résultat dans la table DimProduit du Data Warehouse.

### 0.8.1 Création de la transformation

Une nouvelle transformation `dim_produit.ktr` a été créée dans Pentaho PDI. La figure ci-dessous illustre l'architecture générale composée de trois étapes principales :

- **Table Input** : extraction des produits depuis la base OLTP.
- **Select Values** : renommage de la colonne `id_produit`.
- **Table Output** : chargement des données dans la table `DimProduit` du DWH.

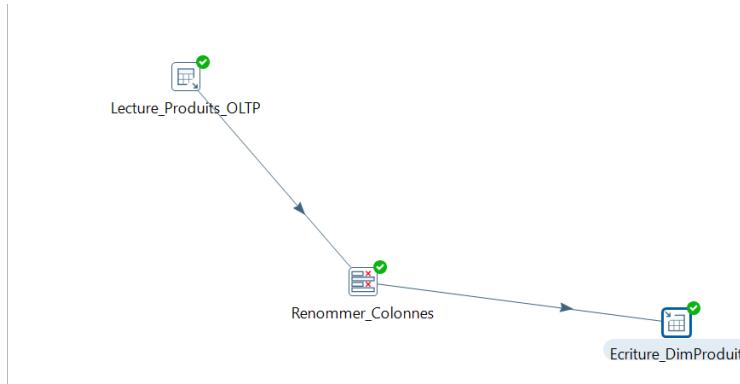


FIGURE 20 – Architecture de la transformation DimProduit dans Pentaho PDI

### 0.8.2 Extraction et renommage des colonnes

L'étape **Table Input** utilise la connexion `OLTP_MySQL` avec la requête SQL suivante :

```
[language=SQL] SELECT idproduit, nomproduit, categorie FROM produits;
```

Ensuite, l'étape **Select Values** permet de renommer la colonne :

- `id_produit` → `id_produit_source`

### 0.8.3 Chargement dans la dimension

Les données sont ensuite envoyées vers l'étape **Table Output**, configurée avec :

- Connexion : `DWH_MySQL`
- Table cible : `DimProduit`
- Option : **Truncate table** activée

### 0.8.4 Résultat obtenu

Après exécution, la transformation charge correctement les données dans la dimension. La figure suivante montre la vérification dans MySQL Workbench :

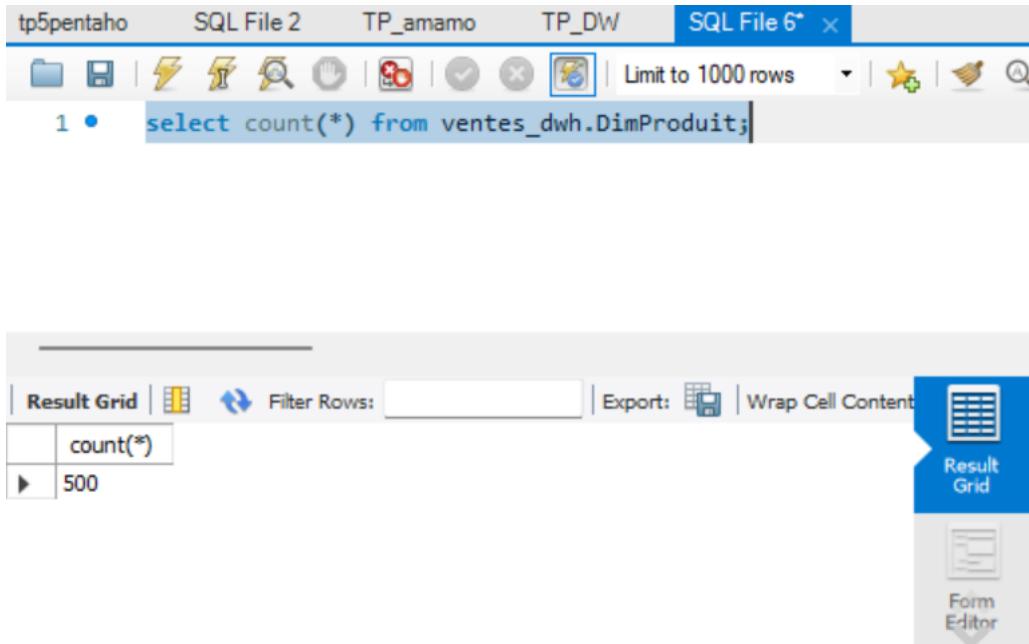


FIGURE 21 – Vérification du chargement de DimProduit dans MySQL Workbench

La commande SQL utilisée pour vérifier est :

[language=SQL] SELECT COUNT(\*) FROM ventes\_dwh.DimProduit;

Le résultat obtenu est de **500 lignes**, ce qui confirme que la transformation a fonctionné comme prévu.

## 0.9 Transformation 3 : Génération de la dimension DimDate

Cette transformation a pour objectif de générer artificiellement la dimension date, couvrant la période 2022-2024, car elle n'existe pas dans l'OLTP.

### 0.9.1 Crédation de la transformation

Une nouvelle transformation `dim_date.ktr` a été créée dans Pentaho PDI. La figure ci-dessous illustre l'architecture générale composée de quatre étapes principales :

- **Generate Rows** : création de 1096 lignes correspondant aux jours de 2022 à 2024.
- **Add Sequence** : génération d'un numéro de jour unique pour chaque ligne.
- **Modified Java Script Value** : calcul de la date complète et des composantes associées (année, mois, jour, trimestre, jour de la semaine, noms).
- **Table Output** : chargement des données dans la table `DimDate` du DWH.

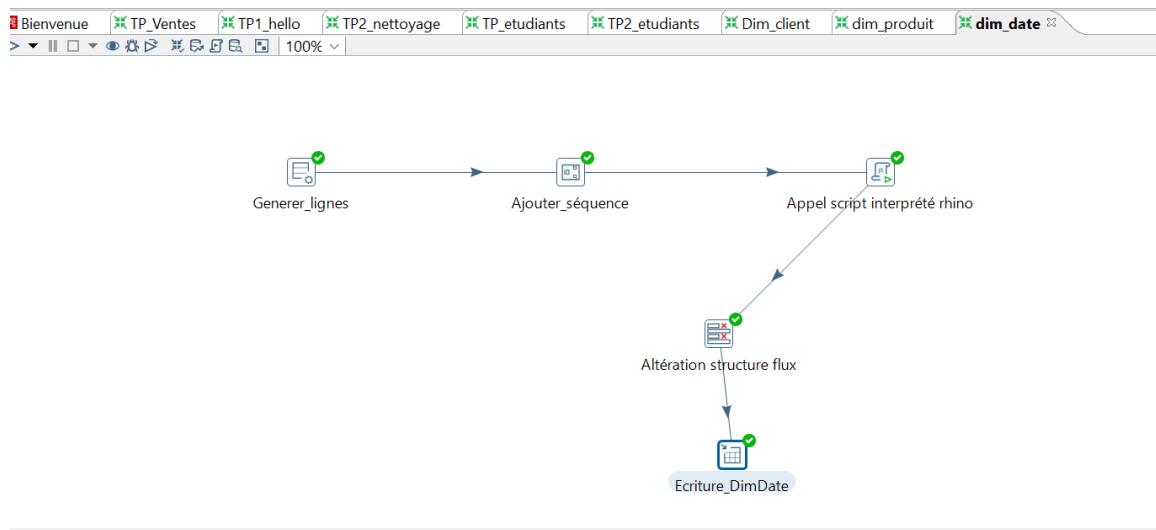


FIGURE 22 – Architecture de la transformation DimDate dans Pentaho PDI

### 0.9.2 Génération des dates et calcul des composantes

Le script JavaScript utilisé dans l'étape **Modified Java Script Value** est le suivant :

### 0.9.3 Chargement dans la dimension

L'étape **Table Output** est configurée avec :

- Connexion : DWH\_MySQL
- Table cible : DimDate
- Option : **Truncate table** activée

### 0.9.4 Résultat obtenu

Après exécution, la transformation charge correctement les 1096 dates dans la dimension. La figure suivante montre la vérification dans MySQL Workbench :

La capture d'écran de MySQL Workbench montre une fenêtre de résultats ('Result Grid') affichant les 1096 premières lignes de la dimension DimDate. Les colonnes sont : id\_date\_dim, date\_complete, annee, trimestre, mois, nom\_mois, jour, et quelques colonnes supplémentaires non visibles. Les données commencent le 1er janvier 2022 (id\_date\_dim 20220101) et se terminent au 31 décembre 2022 (id\_date\_dim 20221231). Un bouton 'Result Grid' est visible sur le côté droit de la fenêtre.

	id_date_dim	date_complete	annee	trimestre	mois	nom_mois	jour	...
▶	20220101	2022-01-01	2022	1	1	Janvier	1	6
	20220102	2022-01-02	2022	1	1	Janvier	2	7
	20220103	2022-01-03	2022	1	1	Janvier	3	1
	20220104	2022-01-04	2022	1	1	Janvier	4	2
	20220105	2022-01-05	2022	1	1	Janvier	5	3
	20220106	2022-01-06	2022	1	1	Janvier	6	4
	...	...	...	...	...	...	...	...
	DimDate 3	x						

FIGURE 23 – Vérification du chargement de DimDate dans MySQL Workbench

La commande SQL utilisée pour vérifier est :

```
[language=SQL] SELECT * FROM ventesdwh.DimDate ORDER BY datec complete LIMIT 10;
```

## 0.10 Transformation 4 : Chargement de la table de faits FactVentes

Cette transformation crée la table de faits en effectuant des jointures entre les données OLTP et les dimensions du DWH.

### 0.10.1 Crédation de la transformation

Une nouvelle transformation `fact_ventes.ktr` a été créée dans Pentaho PDI. L'architecture générale est illustrée ci-dessous :

- **Table Input** : extraction des lignes de commandes depuis l'OLTP.
- **Database Lookup** : récupération des identifiants des dimensions `DimClient`, `DimProduit` et `DimDate`.
- **Modified Java Script Value** : calcul du montant total.
- **Select Values** : sélection des champs finaux.
- **Table Output** : chargement des données dans la table `FactVentes`.

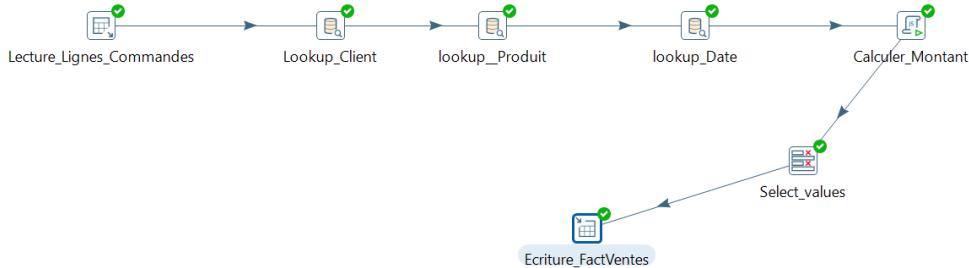


FIGURE 24 – Architecture de la transformation FactVentes dans Pentaho PDI

### 0.10.2 Extraction des données OLTP

Le step **Table Input** utilise la connexion `OLTP_MySQL` avec la requête SQL suivante :

```
[language=SQL] SELECT lc.idligne, lc.idcommande, lc.idproduit, lc.quantite, lc.prixunitaire, c.idclient, c.idcommande;
```

### 0.10.3 Lookup des dimensions

- **Lookup Client** : récupération de `id_client_dim` depuis `DimClient`.

- **Lookup Produit** : récupération de `id_produit_dim` depuis `DimProduit`.
- **Lookup Date** : récupération de `id_date_dim` depuis `DimDate`.

#### 0.10.4 Calcul du montant total

Le step **Modified Java Script Value** effectue le calcul :

```
[language=JavaScript] var montant_total = quantite * prix_unitaire;
```

#### 0.10.5 Sélection des champs finaux et chargement

Les champs sélectionnés dans **Select Values** sont :

- `id_client_dim`
- `id_produit_dim`
- `id_date_dim`
- `quantite`
- `prix_unitaire`
- `montant_total`

L'étape **Table Output** est configurée avec :

- Connexion : `DWH_MySQL`
- Table cible : `FactVentes`
- Option : **Truncate table** activée
- Commit size : 1000

#### 0.10.6 Résultat obtenu

Après exécution, la transformation charge correctement les 100 000 lignes dans la table de faits. La vérification peut se faire avec :

```
[language=SQL] SELECT COUNT(*) FROM ventes_dwh.FactVentes; Le résultat attendu est de 100 000 lignes.
```

The screenshot shows two separate Result Grid windows in MySQL Workbench. The top window displays the schema of a table named 'FactVentes' with the following columns:

Field	Type	Null	Key	Default	Extra
<code>id_vente</code>	int	NO	PRI	NULL	<code>auto_increment</code>
<code>id_client_dim</code>	int	NO	MUL	NULL	
<code>id_produit_dim</code>	int	NO	MUL	NULL	
<code>id_date_dim</code>	int	NO	MUL	NULL	
<code>quantite</code>	int	NO		NULL	
<code>prix_unitaire</code>	decimal(10,2)	NO		NULL	

The bottom window shows the result of a `COUNT(*)` query, which returns a single row with the value `100000`.

FIGURE 25 – Vérification du chargement de FactVentes dans MySQL Workbench

## 0.11 Crédation du Job d’Orchestration Pentaho

Après la création des quatre transformations (*DimClient*, *DimProduit*, *DimDate* et *FactVentes*), nous avons mis en place un Job Pentaho permettant d’orchestrer l’exécution complète du processus ETL. L’objectif d’un Job est d’exécuter les transformations dans le bon ordre, de gérer les dépendances et d’assurer un contrôle d’erreur global.

### 0.11.1 Structure du Job

Le Job complet suit la séquence suivante :

- START
- Charger\_DimClient
- Charger\_DimProduit
- Charger\_DimDate
- Charger\_FactVentes
- Message\_Succes

Chaque transformation n’est exécutée que si la précédente s’est terminée avec succès. À la fin du processus, un message de validation est écrit dans les logs indiquant que le

Data Warehouse est à jour.

### 0.11.2 Étapes de création

1. Création d'un nouveau Job *job\_etl\_complet.kjb*.
2. Ajout de l'entrée **START**.
3. Ajout des transformations et configuration du chemin d'exécution conditionnel (*succes uniquement*).
4. Ajout d'un message de fin pour confirmer l'exécution complète.

### 0.11.3 Capture d'écran du Job

La Figure ci-dessous présente la structure finale du Job d'orchestration :

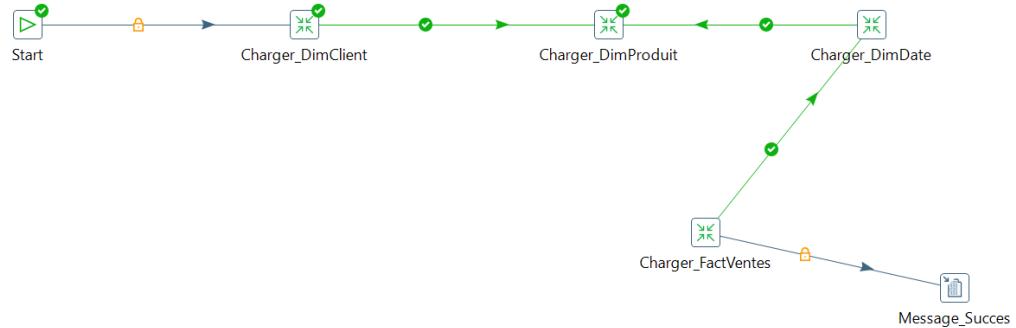


FIGURE 26 – Structure du Job d'orchestration Pentaho

## 0.12 Requêtes OLAP sur le Data Warehouse

Après le chargement complet du Data Warehouse *ventes\_dwh*, nous avons exécuté plusieurs requêtes OLAP dans MySQL Workbench afin d'analyser les ventes selon différentes dimensions. Les requêtes ont été exécutées après sélection de la base :

```
USE ventes_dwh;
```

### 0.12.1 Requête 1 : Chiffre d'affaires par ville

Cette requête permet d'identifier les villes les plus rentables.

**Interprétation** : permet de repérer les zones géographiques générant le plus de chiffre d'affaires.

The screenshot shows a 'Result Grid' interface with the following data:

	ville	chiffre_affaires	nombre_clients	nombre_ventes
▶	Montpellier	27573947.00	748	9203
	Rennes	26805238.00	782	8855
▶	Bordeaux	26198176.00	732	<b>8530</b>
	Nice	25643736.00	729	8523
	Marseille	25190008.00	729	8379
	Strasbourg	25111928.00	711	8355

FIGURE 27 – Résultat de la requête OLAP : CA par ville

### 0.12.2 Requête 2 : Chiffre d'affaires par catégorie de produit

Permet d'identifier les catégories les plus performantes.

**Interprétation :** permet d'identifier les gammes de produits les plus rentables.

The screenshot shows a 'Result Grid' interface with the following data:

	categorie	chiffre_affaires	quantite_vendue	nombre_produits_distincts
▶	Ordinateurs	64813643.00	60514	100
	Téléphones	64517707.00	60122	100
	Accessoires	60121261.00	60127	100
	Tablettes	56764830.00	59296	100
	Montres	55088556.00	59737	100

FIGURE 28 – Résultat : CA par catégorie

### 0.12.3 Requête 3 : Évolution mensuelle des ventes

Analyse de la saisonnalité et de la tendance mensuelle.

**Interprétation :** permet d'observer les hausses et baisses des ventes au fil de l'année.

The screenshot shows a 'Result Grid' interface with the following data:

	annee	mois	nom_mois	chiffre_affaires	nombre_ventes	panier_moyen
▶	2022	1	Janvier	8896246.00	3003	2962.45
	2022	2	Février	8139852.00	2655	3065.86
	2022	3	Mars	8609685.00	2892	2977.07
	2022	4	Avril	8362791.00	2767	3022.33
	2022	5	Mai	7939919.00	2705	2935.28
	2022	6	Juin	7999292.00	2602	3074.29
	2022	7		8458514.00	2607	3070.40
	2022	8		8458514.00	2607	3070.40
	2022	9		8458514.00	2607	3070.40
	2022	10		8458514.00	2607	3070.40
	2022	11		8458514.00	2607	3070.40
	2022	12		8458514.00	2607	3070.40

Result 10

Export: Wrap Cell Content Result Grid Form Editor Read Only

FIGURE 29 – Résultat : évolution mensuelle des ventes

#### 0.12.4 Requête 4 : Top 10 des produits les plus vendus

Identifie les produits leaders.

**Interprétation :** permet d'identifier les produits essentiels à maintenir en stock.

The screenshot shows a 'Result Grid' interface with the following data:

	nom_produit	categorie	quantite_totale_vendue	chiffre_aff
▶	Apple Watch Plus	Montres	751	1334289.00
	Clavier mÃ©canique Ultra	Accessoires	740	1277443.00
	Huawei MatePad Lite	Tablettes	734	136670.00
	Xiaomi 13 Plus	TÃ©lÃ©phones	725	1045934.00
	HP Pavilion Plus	Ordinateurs	714	369852.00
	iPhone 14 Standard	TÃ©lÃ©phones	707	1260157.00
	Surface Pro X	Tablettes	701	1000000.00
	Samsung Galaxy S24	TÃ©lÃ©phones	698	1100000.00
	Lenovo Yoga Tab 3	Tablettes	695	100000.00
	Microsoft Surface Go 2	Tablettes	690	100000.00

Result Grid Form Editor

FIGURE 30 – Résultat : Top 10 des produits

#### 0.12.5 Requête 5 : Analyse croisée trimestre-catégorie

Analyse multidimensionnelle croisant le temps et la catégorie.

**Interprétation :** montre quelles catégories fonctionnent le mieux selon les périodes de l'année.

The screenshot shows a Power BI interface with a 'Result Grid' view. The grid displays data from a MySQL database with the following schema:

	annee	trimestre	categorie	chiffre_affaires	quantite_vendue
▶	2022	1	Téléphones	5474153.00	5004
	2022	1	Ordinateurs	5380927.00	5081
	2022	1	Accessoires	5156742.00	5135
	2022	1	Tablettes	4934979.00	5287
	2022	1	Montres	4698982.00	5208
	2022	2	Ordinateurs	5572260.00	5183

The interface includes a toolbar with 'Result Grid', 'Filter Rows', 'Export', and 'Wrap Cell Content' buttons. A sidebar on the right shows 'Result Grid' selected.

FIGURE 31 – Résultat : analyse trimestre-catégorie

### 0.12.6 Avantages du schéma en étoile

- Requêtes rapides même sur de gros volumes.
- SQL simple (peu de jointures).
- Dimensions enrichies permettant une analyse flexible.
- Idéal pour l'analyse OLAP.

## 0.13 Power BI - Reporting et Visualisation

Nous allons créer un tableau de bord interactif dans Power BI pour visualiser nos données du Data Warehouse.

### 0.13.1 Prérequis

- Télécharger et installer Power BI Desktop (gratuit) depuis le site de Microsoft.
- Assurez-vous d'avoir le connecteur MySQL pour Power BI.

### 0.13.2 Étape 1 : Se connecter à MySQL depuis Power BI

1. Lancer Power BI Desktop.
  2. Obtenir les données : MySQL Database.
  3. Configurer la connexion. Remplissez :
    - Serveur : localhost
    - Base de données : ventes\_dwh
    - Nom d'utilisateur : root
    - Mot de passe : votre mot de passe
- Cliquez sur **Connexion**.

## Data >

Search

- ✓ 📊 ventes\_dwh.dimclient
  - email
  - id\_client\_dim
  - id\_client\_source
  - nom\_complet
  - ville

- ✓ 📊 ventes\_dwh.dimdate ...
  - $\sum$  annee
  - >  📅 date\_complete
    - id\_date\_dim
    - $\sum$  jour
    - $\sum$  jour\_semaine
    - $\sum$  mois ...
      - nom\_jour
      - nom\_mois
      - $\sum$  trimestre

- ✓ 📊 ventes\_dwh.dimproduit ...
  - categorie
  - id\_produit\_dim
  - id\_produit\_source
  - nom\_produit

ventes_dwh factventes		...
<input type="checkbox"/>	id_client_dim	
<input type="checkbox"/>	id_date_dim	
<input type="checkbox"/>	id_produit_dim	
<input type="checkbox"/>	$\sum$ id_vente	
<input type="checkbox"/>	$\sum$ montant_total	
<input type="checkbox"/>	$\sum$ prix_unitaire	
<input type="checkbox"/>	$\sum$ quantite	

FIGURE 32 – Connexion à la base MySQL dans Power BI

### 0.13.3 Étape 2 : Importer les tables du Data Warehouse

1. Sélectionnez les tables DimClient, DimProduit, DimDate, FactVentes et cliquez sur **Charger**.

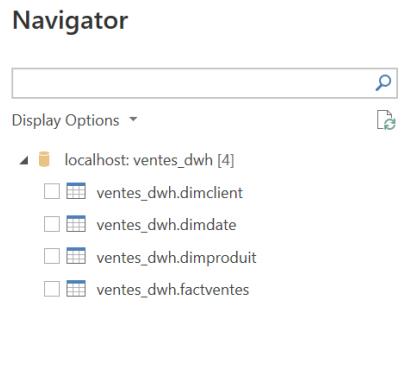


FIGURE 33 – Tables importées dans Power BI

### 0.13.4 Étape 3 : Vérifier et configurer le modèle de données

1. Ouvrir la vue Modèle.

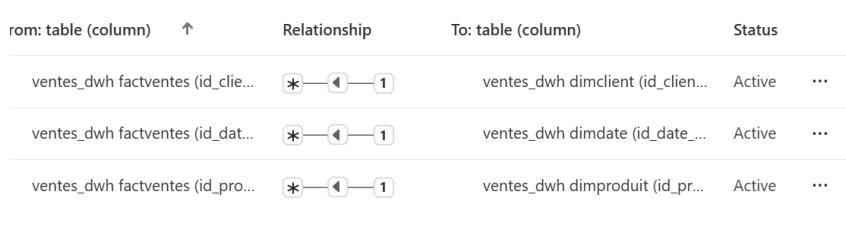


FIGURE 34 – Relations entre les tables dans Power BI

- Vérifier les relations automatiques ou créer manuellement si nécessaire.

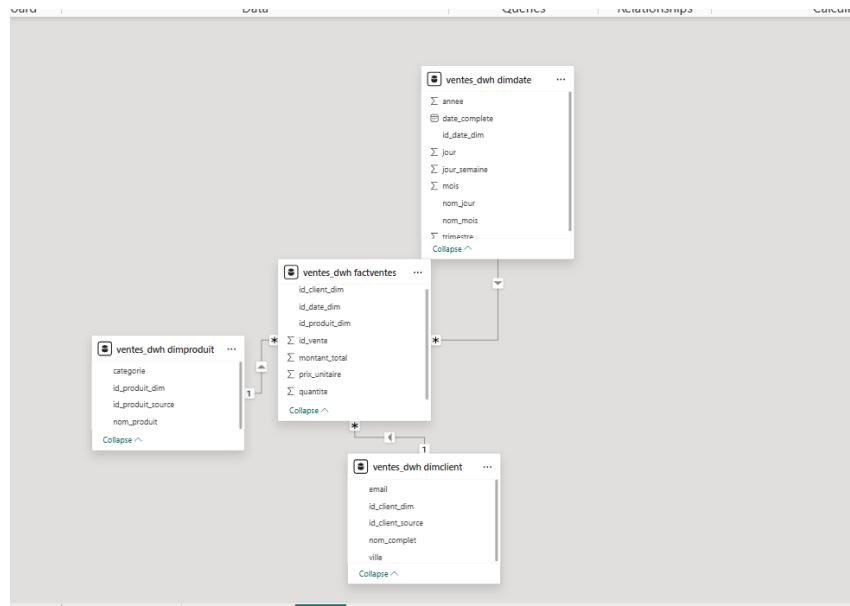


FIGURE 35 – Diagramme en étoile avec FactVentes au centre et dimensions autour

## 0.14 Étape 4 : Créer les visualisations

Revenons à la vue **Rapport** (icône graphique à gauche) pour créer nos visuels.

### 0.14.1 Visuel 1 : Chiffre d'affaires par ville (Graphique à barres)

- Ajouter un graphique à barres groupées.
- Configurer les champs :
  - Axe : DimClient.ville
  - Valeurs : FactVentes.montant\_total
- Personnaliser :
  - Titre : “Chiffre d'affaires par ville”
  - Activer les étiquettes de données
  - Modifier les couleurs si souhaité
- Interprétation : montre quelles villes génèrent le plus de revenus.

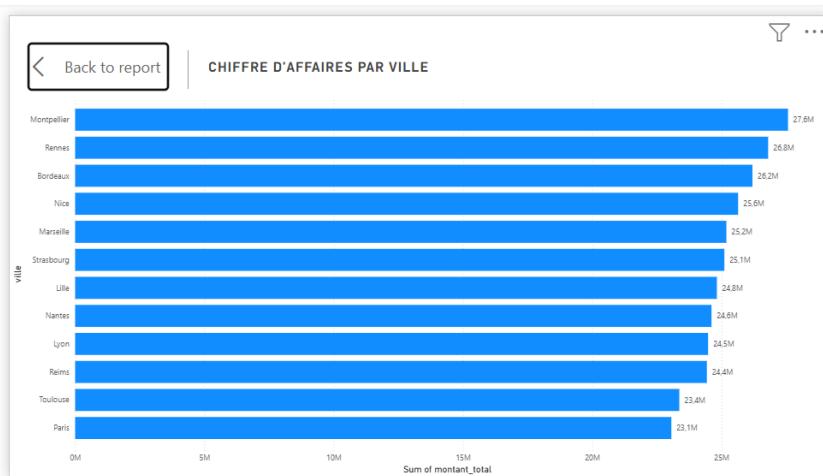


FIGURE 36 – Chiffre d'affaires par ville

### 0.14.2 Visuel 2 : Chiffre d'affaires par catégorie (Graphique en secteurs)

1. Ajouter un graphique en secteurs (Pie chart).
2. Configurer les champs :
  - Légende : DimProduit.categorie
  - Valeurs : FactVentes.montant\_total
3. Personnaliser :
  - Titre : “Répartition du CA par catégorie”
  - Activer les étiquettes de détails
  - Choisir des couleurs différentes pour chaque catégorie
4. Interprétation : contribution relative de chaque catégorie au CA.

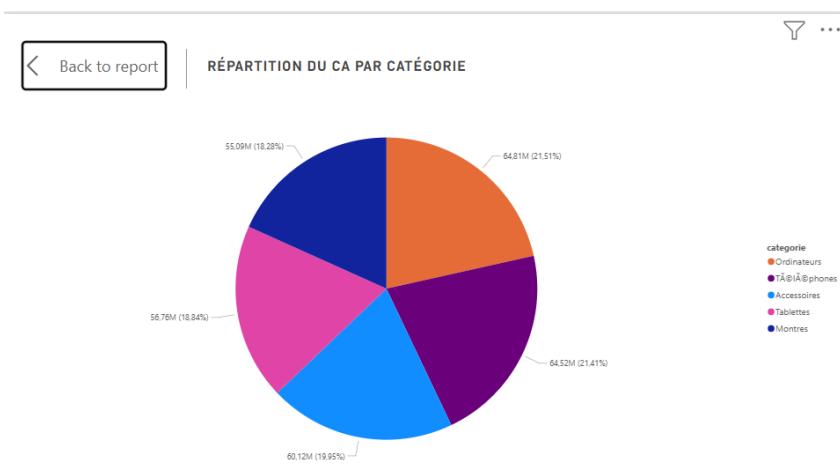


FIGURE 37 – Répartition du chiffre d'affaires par catégorie

### 0.14.3 Visuel 3 : Évolution des ventes mensuelles (Graphique en courbes)

1. Ajouter un graphique en courbes (Line chart).
2. Configurer les champs :
  - Axe X : DimDate.date\_complete
  - Valeurs : FactVentes.montant\_total
3. Hiérarchie temporelle : sélectionner Année, Trimestre ou Mois selon besoin.
4. Personnaliser :
  - Titre : “Évolution mensuelle du chiffre d’affaires”
  - Activer les marqueurs
  - Choisir une couleur distinctive (ex : bleu foncé)
5. Interprétation : montre la saisonnalité et les tendances.

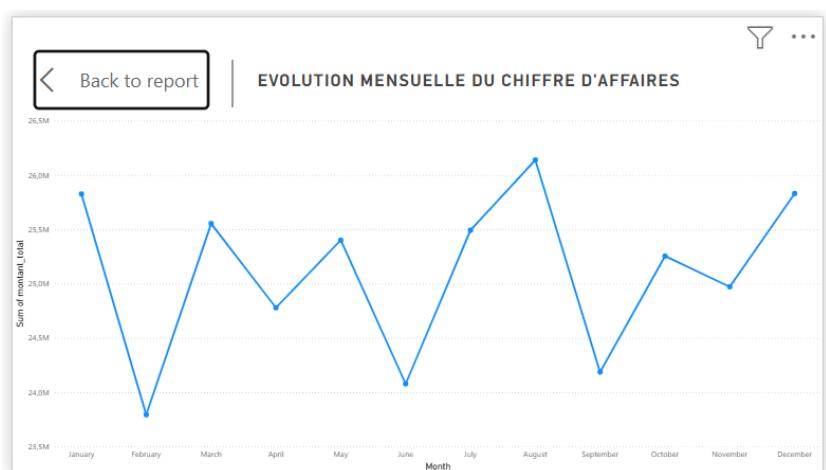


FIGURE 38 – Évolution mensuelle du chiffre d’affaires

### 0.14.4 Visuel 4 : Top 10 des produits (Graphique à barres horizontales)

1. Ajouter un graphique à barres horizontales.
2. Configurer les champs :
  - Axe Y : DimProduit.nom\_produit
  - Valeurs : FactVentes.quantite
3. Limiter au Top 10 :
  - Dans Filtres, choisir Top N
  - Afficher les 10 premiers par Somme de quantite
4. Personnaliser :

- Titre : “Top 10 des produits les plus vendus”
  - Trier les barres par ordre décroissant
  - Activer les étiquettes de données
5. Interprétation : identifie les produits phares pour les promotions et mises en avant.

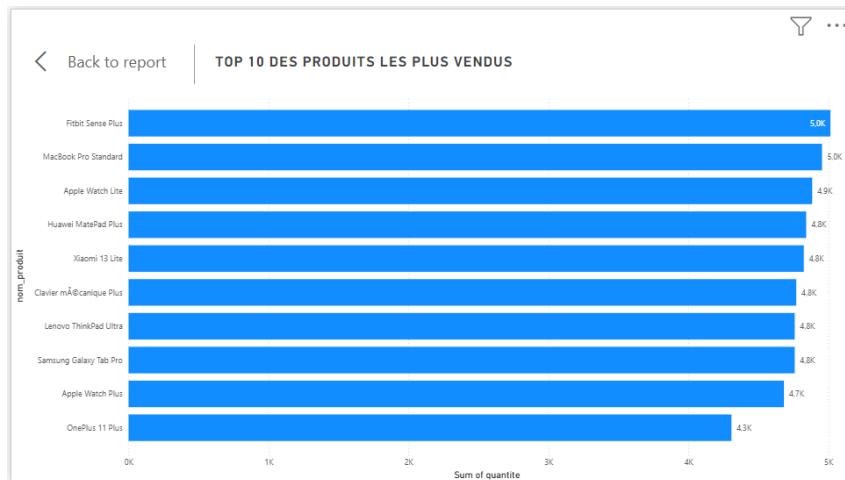


FIGURE 39 – Top 10 des produits les plus vendus

## 0.15 Étape 5 : Ajouter des segments (Slicers) pour l’interactivité

Les segments permettent de filtrer dynamiquement tous les visuels du rapport.

### 0.15.1 5.1 - Ajouter un segment Année

1. Cliquez sur une zone vide.
2. Sélectionnez l’icône **Segment (Slicer)** dans le panneau Visualisations.
3. Glissez `DimDate.annee` vers le champ du segment.
4. Positionnez ce segment en haut à gauche du rapport.

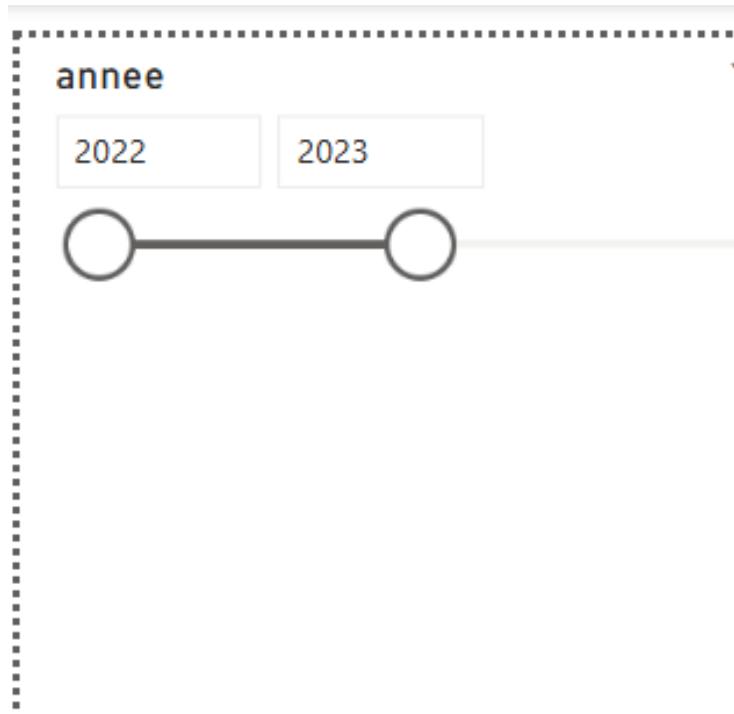


FIGURE 40 – Segment Année pour filtrer les visuels

### 0.15.2 5.2 - Ajouter un segment Catégorie

1. Ajoutez un autre segment.
2. Glissez DimProduit.categorie vers le champ du segment.
3. Positionnez-le à côté du segment Année.



FIGURE 41 – Segment Catégorie pour filtrer les visuels

### 0.15.3 5.3 - Tester l'interactivité

- Cliquer sur “2023” dans le segment Année : tous les visuels se mettent à jour pour afficher uniquement les données 2023.
- Cliquer sur “Ordinateurs” dans le segment Catégorie : les visuels se filtrent encore plus.
- Cliquer sur une barre du graphique “CA par ville” : tous les autres visuels se filtrent pour cette ville.

*Note :* Cette interactivité bidirectionnelle (cross-filtering) est l'une des forces majeures de Power BI. Elle permet aux utilisateurs d'explorer les données de manière intuitive sans écrire de SQL.

## 0.16 Étape 6 : Créer des mesures DAX (optionnel mais recommandé)

Pour enrichir l'analyse, nous créons quelques mesures calculées avec le langage DAX.

### 0.16.1 6.1 - Mesure “CA Total”

1. Dans le panneau **Champs**, clic droit sur **FactVentes** → **Nouvelle mesure**.
2. Tapez la formule :

$$CATotal = SUM(FactVentes[montant\_total])$$

3. Appuyez sur Entrée.

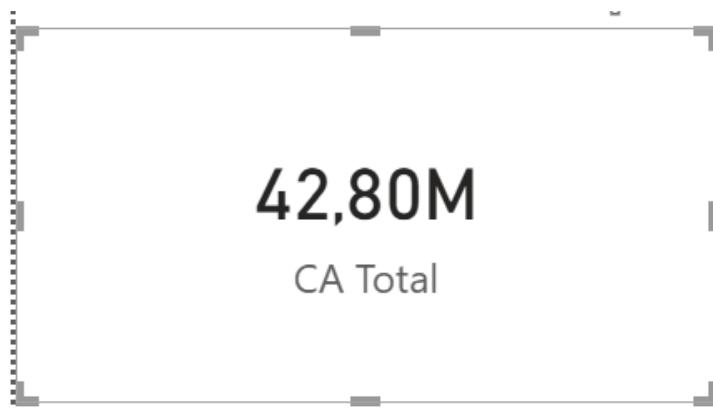


FIGURE 42 – Crédit de la mesure “CA Total”

## 0.16.2 6.2 - Mesure “Nombre de ventes”

1. Nouvelle mesure sur FactVentes :

$$Nombre de Ventes = COUNT(FactVentes[id\_vente])$$



FIGURE 43 – Création de la mesure “Nombre de Ventes”

## 0.16.3 6.3 - Mesure “Panier Moyen”

1. Nouvelle mesure :

$$PanierMoyen = DIVIDE([CATotal], [Nombre de Ventes], 0)$$

2. La fonction DIVIDE gère automatiquement les divisions par zéro.

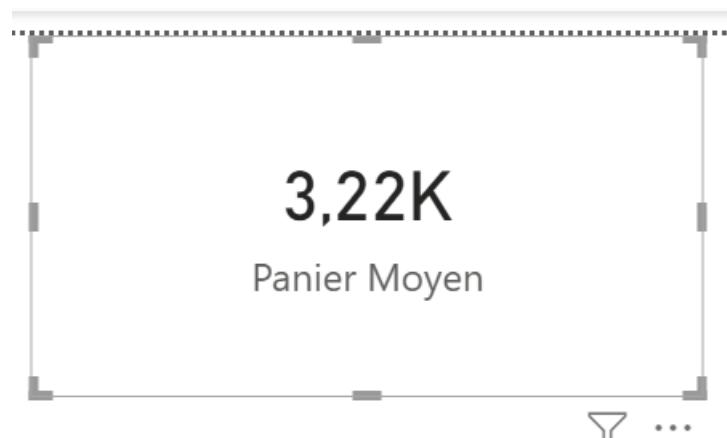


FIGURE 44 – Création de la mesure “Panier Moyen”

#### 0.16.4 6.4 - Mesure “Clients Uniques”

1. Nouvelle mesure :

$$ClientsUniques = DISTINCTCOUNT(FactVentes[id\_client\_dim])$$

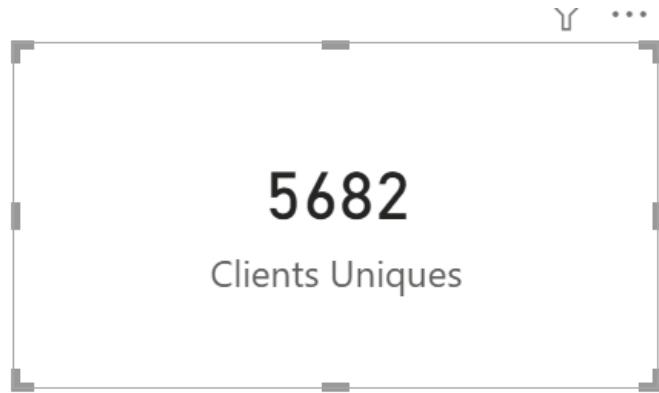


FIGURE 45 – Création de la mesure “Clients Uniques”

#### 0.16.5 6.5 - Utiliser les mesures

- Créez des cartes (**Card**) pour afficher :
  - **CA Total**
  - **Panier Moyen**
  - **Nombre de Ventes**
  - **Clients Uniques**
- Positionnez ces 4 cartes en haut du rapport comme des KPI.

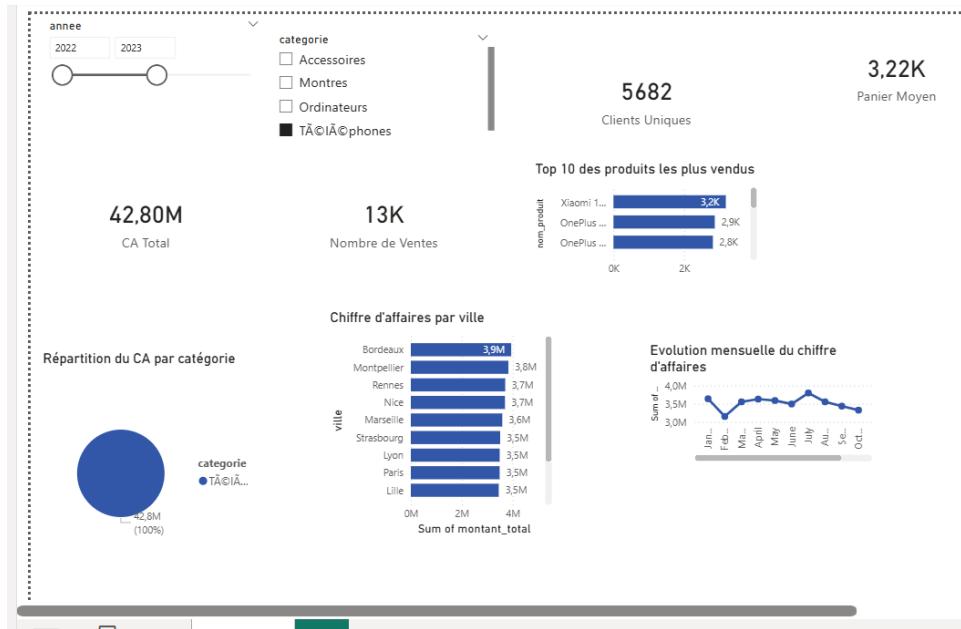


FIGURE 46 – Dashboard final : 4 KPI, 2 segments et 4 visualisations principales

*Résultat attendu* : un tableau de bord complet avec interactivité totale entre tous les visuels.

## 0.17 Étape 9 : Créer une page de détails (Drill-through)

Pour une analyse approfondie, nous créons une page de détails accessible en cliquant sur un élément.

### 0.17.1 9.1 - Créeer une nouvelle page

1. En bas de l'écran, cliquez sur le + pour ajouter une page.
2. Renommez la page "Détails Produit".

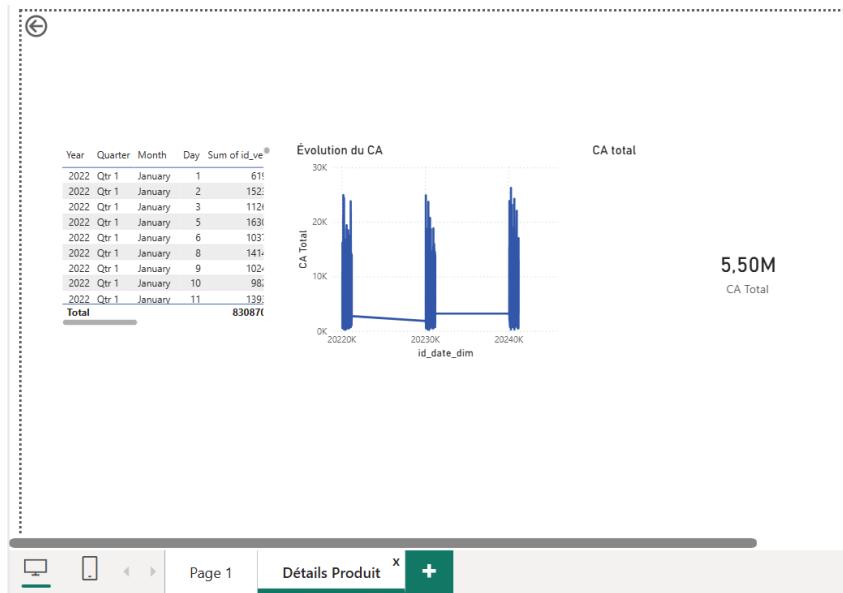


FIGURE 47 – Nouvelle page “Détails Produit”

## 0.17.2 9.3 - Ajouter des visuels détaillés

**1. Tableau des ventes du produit sélectionné** Ajoutez un tableau montrant toutes les ventes du produit sélectionné.

Year	Quarter	Month	Day	Sum of id_vente	Sum of montant_total	Sum of prix_unitaire	Sum of quantite	categorie
2022	Qtr 1	January	1	776656	28 781,00	15 961,20	28	Accessoires
2022	Qtr 1	January	1	1358052	67 900,00	24 503,61	79	Montres
2022	Qtr 1	January	1	961663	87 057,00	22 705,50	74	Ordinateurs
2022	Qtr 1	January	1	1093168	72 829,00	24 284,00	66	Téléphones
2022	Qtr 1	January	1	1147539	65 861,00	23 149,66	63	Tablettes
2022	Qtr 1	January	2	796031	39 083,00	15 471,13	53	Accessoires
2022	Qtr 1	January	2	709063	42 251,00	12 090,94	56	Montres
2022	Qtr 1	January	2	741127	42 693,00	13 889,72	42	Ordinateurs
2022	Qtr 1	January	2	1513249	103 743,00	32 541,21	100	Téléphones
2022	Qtr 1	January	2	1792067	93 281,00	28 541,45	87	Tablettes
2022	Qtr 1	January	3	583966	32 111,00	9 280,08	44	Accessoires
2022	Qtr 1	January	3	610851	35 971,00	15 863,69	35	Montres
2022	Qtr 1	January	3	815464	35 012,00	10 454,21	40	Ordinateurs
2022	Qtr 1	January	3	981427	42 556,00	12 834,88	46	Téléphones
2022	Qtr 1	January	3	1121512	54 975,00	20 463,48	62	Tablettes
2022	Qtr 1	January	4	500186	32 576,00	10 454,06	38	Accessoires
2022	Qtr 1	January	4	475323	34 068,00	10 098,92	37	Montres
2022	Qtr 1	January	4	490207	47 562,00	12 948,76	34	Ordinateurs
<b>Total</b>				<b>5000050000</b>	<b>301 305 997,00</b>	<b>100 362 315,05</b>	<b>299796</b>	

FIGURE 48 – Tableau montrant toutes les ventes du produit sélectionné

**2. Graphique en courbes de l'évolution des ventes** Ajoutez un graphique en courbes montrant l'évolution des ventes de ce produit dans le temps.

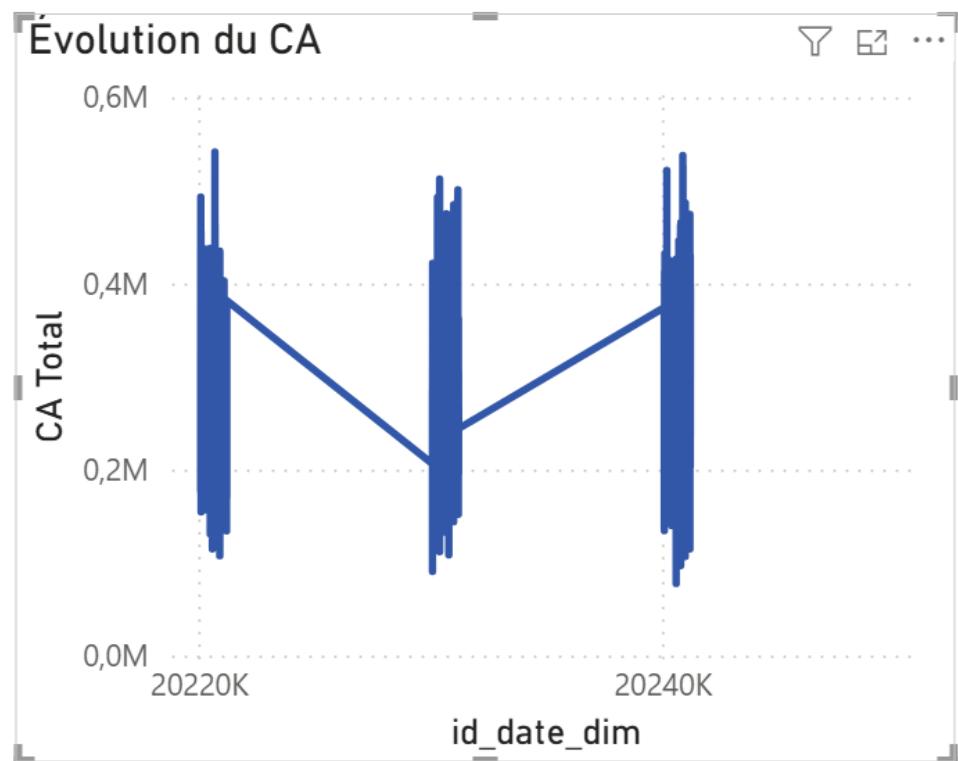


FIGURE 49 – Évolution des ventes du produit dans le temps

**3. Carte du CA total du produit** Ajoutez une carte montrant le chiffre d'affaires total du produit.

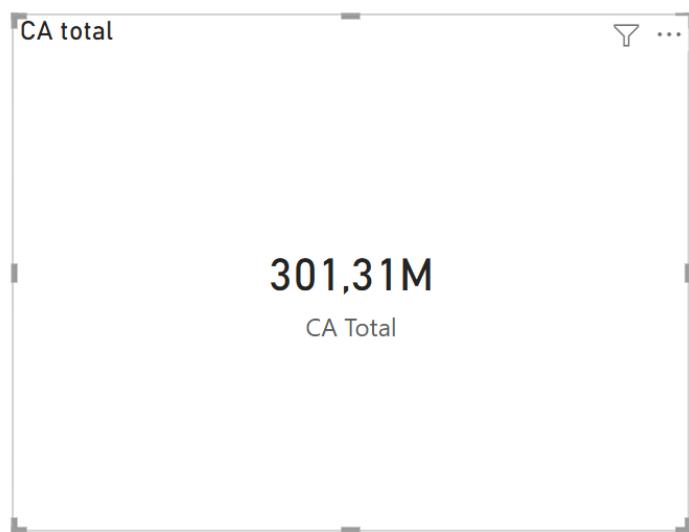


FIGURE 50 – Carte montrant le CA total du produit sélectionné

### 0.17.3 9.4 - Tester le drill-through

1. Revenir à la première page.
2. Clic droit sur une barre du graphique “Top 10 produits”.

3. Sélectionner Drill-through → Détails Produit.
4. La page de détails s'affiche, filtrée sur le produit sélectionné.
5. Cliquez sur la flèche de retour en haut à gauche pour revenir.

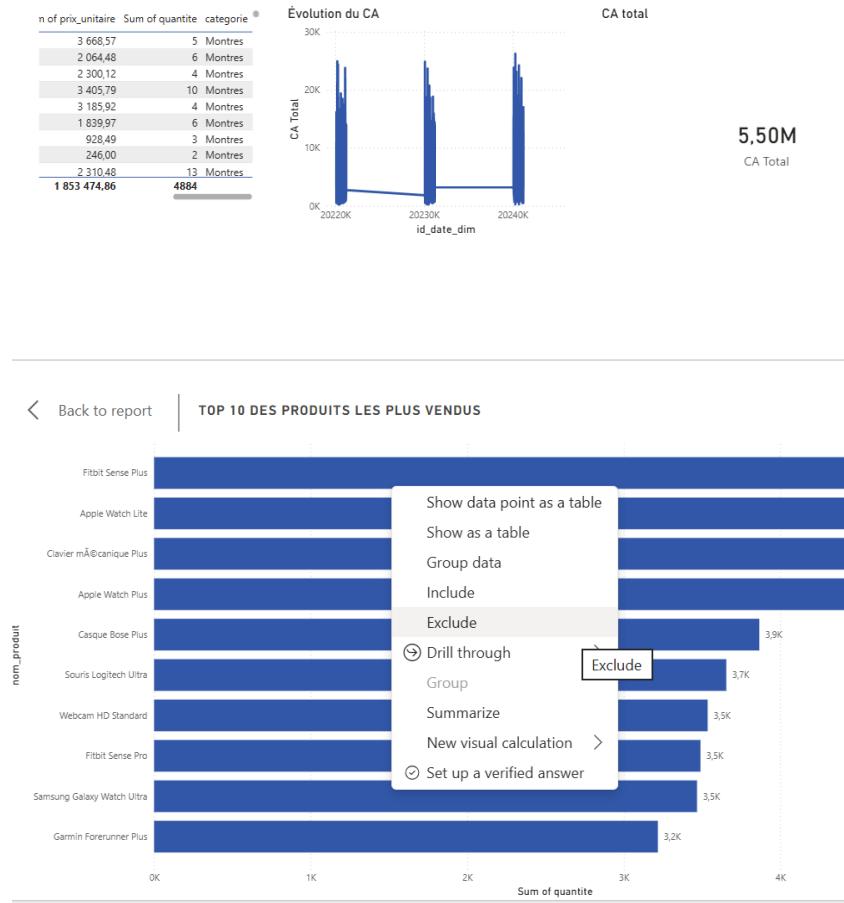


FIGURE 51 – Test du Drill-through : page filtrée sur le produit sélectionné

*Remarque :* Le drill-through permet aux utilisateurs d'explorer les données en profondeur sans surcharger le tableau de bord principal. C'est une fonctionnalité très appréciée par les analystes métier.